

**UNIVERSITATEA BABEȘ-BOLYAI CLUJ-NAPOCA  
FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ  
SPECIALIZAREA INFORMATICĂ**

## **LUCRARE DE LICENȚĂ**

### **Detectarea apelurilor malițioase folosind spectrograme audio**

**Conducător științific  
Drd. Claudia-Ioana Coste**

*Absolvent  
Marinescu Dragoș*

2026



---

## ABSTRACT

---

Abstract: un rezumat în limba engleză cu prezentarea, pe scurt, a conținutului pe capitole, punând accent pe contribuțiile proprii și originalitate

# Cuprins

|          |                                                                     |           |
|----------|---------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introducere</b>                                                  | <b>1</b>  |
| 1.1      | Introducere . . . . .                                               | 1         |
| 1.2      | Motivație . . . . .                                                 | 1         |
| 1.3      | Obiective . . . . .                                                 | 2         |
| 1.4      | Structura lucrării . . . . .                                        | 2         |
| <b>2</b> | <b>Stadiul actual al cunoașterii în domeniu</b>                     | <b>3</b>  |
| 2.1      | Soluții tradiționale . . . . .                                      | 3         |
| 2.2      | Soluții bazate pe Deep Learning . . . . .                           | 4         |
| 2.3      | Alte soluții care folosesc Machine Learning . . . . .               | 5         |
| 2.4      | Seturi de date . . . . .                                            | 5         |
| 2.5      | Analiză critică a literaturii de specialitate . . . . .             | 6         |
| <b>3</b> | <b>Fundamente teoretice</b>                                         | <b>8</b>  |
| 3.1      | Parametrizarea spectrală . . . . .                                  | 8         |
| <b>4</b> | <b>Dezvoltarea aplicației</b>                                       | <b>9</b>  |
| 4.1      | Definiția problemei . . . . .                                       | 9         |
| 4.2      | Analiza și arhitectura aplicației . . . . .                         | 9         |
| 4.3      | Dezvoltarea Aplicației . . . . .                                    | 9         |
| 4.4      | Manual de utilizare . . . . .                                       | 9         |
| 4.5      | Testare . . . . .                                                   | 9         |
| <b>5</b> | <b>Experimente</b>                                                  | <b>10</b> |
| 5.1      | Performanța pe setul intern de testare . . . . .                    | 10        |
| 5.2      | Validarea statistică prin <i>K</i> -Fold Cross-Validation . . . . . | 11        |
| 5.3      | Evaluarea modelului pe date externe . . . . .                       | 12        |
| 5.3.1    | Ajustarea fină cu date Partially Fake . . . . .                     | 12        |
| 5.3.2    | Reechilibrarea setului de date . . . . .                            | 14        |
| 5.4      | Simularea canalului telefonic . . . . .                             | 16        |
| 5.4.1    | Rezultate . . . . .                                                 | 17        |

|          |                                         |           |
|----------|-----------------------------------------|-----------|
| 5.5      | Comparația finală și discuție . . . . . | 18        |
| <b>6</b> | <b>Concluzii</b>                        | <b>20</b> |
| <b>A</b> | <b>YouTube Dataset Sources</b>          | <b>21</b> |
|          | <b>Bibliografie</b>                     | <b>24</b> |

# Capitolul 1

## Introducere

### 1.1 Introducere

Introducere: obiectivele lucrării și descrierea succintă a capitolelor, prezentarea te-meii, prezentarea contribuției proprii, respectiv a rezultatelor originale și menționarea (dacă este cazul) a sesiunii de comunicări unde a fost prezentată sau a revistei unde a fost publicată.

### 1.2 Motivație

Apelurile telefonice malițioase reprezintă o amenințare tot mai acută la nivel global și au început să capete o prezență semnificativă și în România. Atacatorii utilizează tehnici sofisticate precum *spoofing*, unde numărul de telefon afișat este falsificat pen-tru a induce victima în eroare, precum și inginerie socială pentru a determina divul-garea de informații personale sau financiare [Dir24, Inf24].

Aceste atacuri nu doar că generează pierderi financiare globale de ordinul mi-liardelor [Tru21], dar afectează și încrederea utilizatorilor în comunicațiile digitale. Pe plan local, numărul incidentelor raportate este în creștere constantă, conform rapoartelor DNSC și Poliției Române [Dir24]. În contextul acestor evoluții, este esențial să dezvoltăm metode robuste de detecție a apelurilor malițioase, bazate pe analiza directă a semnalului audio, pentru a complementa și depăși limitările abordărilor clasice bazate pe metadata sau transcrieri.

Determinarea de a aborda această problemă provine atât din gravitatea impac-tului asupra utilizatorilor, cât și din relevanța sa internațională. Lucrarea de față își propune, prin utilizarea tehnicilor de învățare profundă și analiza spectrograme-lor, să contribuie la prevenirea acestor atacuri, crescând securitatea comunicațiilor

și protecția datelor personale.

## **1.3 Obiective**

## **1.4 Structura lucrării**

# Capitolul 2

## Stadiul actual al cunoașterii în domeniu

Acest capitol realizează o analiză a literaturii de specialitate, urmărind evoluția metodelor de detectare a apelurilor malițioase. Prezentarea este organizată cronologic și tehnologic, pornind de la soluțiile clasice (bazate pe metadate și text), continuând cu utilizarea rețelelor neuronale profunde pentru analiza audio și încheind cu o descriere a seturilor de date relevante și a provocărilor actuale.

### 2.1 Soluții tradiționale

Primele tentative de detectare a spam-ului telefonic s-au concentrat preponderent pe analiza metadatelor, ocolind analiza conținutului audio. Această direcție a fost favorizată de accesul facil al operatorilor la istoricul apelurilor (Call Detail Records - CDR). Divya Potnuru realizează în [Pot24] o revizuire a acestor metode clasice de Machine Learning aplicate pe date tabelare. În studiul său, autoarea arată cum algoritmi consacrați, precum Naive Bayes, Random Forest și Adaptive Boosting, pot clasifica apelurile folosind atribute precum durata, frecvența apelării unui număr țintă, originea geografică și momentul zilei. Deși acești algoritmi oferă avantajul vitezei și pot filtra atacurile volumetrice simple, ei prezintă o vulnerabilitate majoră: incapacitatea de a detecta atacurile de tip *spoofing* (unde identitatea apelantului este falsificată) și ineficiența în fața atacatorilor care își modifică dinamic comportamentul de apelare pentru a evita regulile statistice.

O altă strategie tradițională a implicat utilizarea Procesării Limbajului Natural (NLP) aplicată pe transcrierile apelurilor. Această metodă necesită un pas intermediar de conversie a vocii în text (Speech-to-Text - STT) pentru a căuta cuvinte cheie specifice fraudelor (ex. „cont bancar”, „câștigat”, „urgentă”). Elizalde et al. [BD21]



explică în introducerea lucrării lor de ce această abordare este limitată. Principala problemă identificată este dependența critică de acuratețea sistemului STT; într-un mediu zgomotos sau în cazul unei calități scăzute a transmisiei, erorile de transcriere pot compromite total clasificarea. Mai mult, analiza exclusivă a textului ignoră complet informația paralingvistică, tonul vocii, pauzele nenaturale sau zgomotele de fundal sintetice, care sunt adesea indicatori mai puternici ai unei fraude decât cuvintele rostite.

## 2.2 Soluții bazate pe Deep Learning

Odată cu creșterea puterii de calcul, cercetarea s-a reorientat către analiza directă a semnalului audio folosind tehnici de învățare profundă (*Deep Learning*). Această abordare transformă semnalul audio într-o reprezentare vizuală (spectrogramă), permițând rețelelor neuronale să învețe tipare complexe direct din sunet.

Un studiu de referință este cel realizat de Elizalde și Emmanouilidou la Microsoft Research [ED21]. Autorii au propus o metodă de clasificare bazată pe extragerea caracteristicilor acustice direct din fișierele audio, utilizând descriptori precum MFCC (Mel-Frequency Cepstral Coefficients) și spectrul Log-Mel. Rezultatele experimentale au arătat o diferență clară în funcție de dificultatea sarcinii: sistemul a atins o acuratețe de 93% în diferențierea roboților de oameni (probabil datorită artefactelor sintetice evidente), dar a scăzut la 83% în detectarea intenției malițioase (spam) în apelurile umane. Această discrepanță subliniază faptul că detectarea spam-ului uman, care nu prezintă defecte audio clare, rămâne o provocare deschisă.

Pentru a determina cea mai eficientă reprezentare a sunetului pentru rețelele neuronale, Kim et al. [KLLK25] au publicat recent un studiu comparativ asupra detecției anomaliilor audio. Cercetătorii au antrenat o rețea convoluțională (CNN) folosind trei tipuri de intrări: spectrograme standard, mel-spectrograme și MFCC. Rezultatele au fost concludente în favoarea mel-spectrogramelor, modelul atingând o acuratețe de 97,13%, comparativ cu 95,22% pentru spectrogramele simple și 93,78% pentru MFCC. Autorii explică această performanță prin faptul că filtrele Mel emulează percepția auditivă umană, accentuând trăsăturile critice din frecvențele joase și reducând zgomotul irelevant. Această validare științifică justifică alegerea mel-spectrogramei ca feature de bază pentru obținerea celei mai bune performanțe.

Superioritatea rețelelor convoluționale (CNN) în analiza spectrală este susținută și de alte domenii conexe. Trinh și O'Brien [TO19] au demonstrat că tratarea semnalului audio ca pe o imagine permite CNN-urilor să învețe filtre spațiale ierarhice,

obținând o acuratețe de peste 95% în clasificarea vorbirii patologice. Similar, Khan et al. [KASF21] au aplicat aceeași logică pentru detecția intruziunilor în rețea, transformând traficul de date în spectrograme și obținând o acuratețe de aproximativ 98,75%. Aceste rezultate confirmă capacitatea CNN-urilor de a detecta pattern-uri complexe invizibile în analiza temporală simplă, o proprietate esențială pentru detectarea audio-ului malițios care lasă urme spectrale distincte.

## 2.3 Alte soluții care folosesc Machine Learning

În afara paradigmei Deep Learning, există o direcție solidă de cercetare concentrată pe ingineria trăsăturilor (*feature engineering*) specifice pentru detectarea falsificării vocii (*anti-spoofing*).

O analiză cuprinzătoare a acestui domeniu este realizată de Li et al. în [MLZ24]. Autorii trec în revistă metodele care utilizează clasificatori statistici, precum modelele de amestec Gaussian (GMM), în combinație cu caracteristici avansate precum Constant-Q Cepstral Coefficients (CQCC). Acești coeficienți folosesc transformata Constant-Q (CQT), care oferă o rezoluție mai bună la frecvențele joase și o rezoluție temporală superioară la frecvențele înalte. Todisco et al. [TDE16] au validat CQCC ca un standard de referință în competițiile ASVspoof, demonstrând că sunt foarte eficienți în detectarea artefactelor fine generate de *vocodere* și motoare Text-to-Speech (TTS), uneori depășind rețelele neuronale complexe dacă datele sunt limitate.

Totuși, limitările acestor metode devin evidente în fața atacurilor hibride. Așa cum arată AlAli și Theodorakopoulos în lucrarea [AT], modelele bazate pe CQCC-GMM obțin performanțe slabe (EER peste 25%) când sunt testate pe atacuri parțial falsificate. Din acest motiv, literatura recomandă tot mai des construirea unor modele *hibride* sau *ensemble*: care combină puterea de abstractizare a Deep Learning (CNN pe spectrograme) cu precizia statistică a metodelor clasice (ML pe caracteristici ingineresti), pentru a aborda apelurile sofisticate.

## 2.4 Seturi de date

Dezvoltarea unui sistem robust de detecție depinde critic de diversitatea datelor de antrenament. În cadrul acestei lucrări sunt analizate patru seturi de date principale, completate de resurse pentru generarea de date sintetice.

Primul set de date relevant este „Robocall Audio Dataset”, publicat de Prasad

și Reaves de la North Carolina State University [Sat23]. Acesta conține 1101 de înregistrări reale ale unor apeluri automate sau semi-automate folosite de apelanți malițioși în scopuri frauduloase sau ilegale. Datele sunt convertite în format WAV la 16kHz și includ doar canalul apelantului. Setul de date oferă realismul necesar (zgomot de canal, scenarii reale), și oferă o proporție de limbă engleză de aproximativ 97,5%.

Pentru a studia atacurile avansate, AlAli și Theodorakopoulos au publicat setul de date „RFP Dataset” (Real, Fake, Partially Fake), disponibil pe Zenodo [AA23]. Acesta este un corpus masiv, de peste 40 GB, care include cinci tipuri de audio: real, TTS, voice conversion (VC), zgomot și, cel mai important, *parțial falsificat* (PF). Clasa PF conține exemple în care doar segmente mici dintr-o înregistrare reală sunt înlocuite cu voce sintetică, simulând atacuri de manipulare a contextului. Analiza acestui set [AT] a arătat că algoritmi actuali au dificultăți majore în a detecta aceste inserții fine.

Pentru a folosi apeluri reale, autentice și nefrauduloase, am folosit setul de date “CallHome American English Speech”, pus la dispoziție de Linguistic Data Consortium (LDC) și accesat prin intermediul platformei Kaggle [(LD97)]. Aici găsim peste 120 de înregistrări cu durate cuprinse între 5 și 10 minute ale unor apeluri telefonice realizate între vorbitori nativi de engleză care erau în mare parte prieteni sau din aceeași familie. Acest set de date este considerat un standard în domeniu pentru analiza vorbirii spontane, oferind varietate acustică și zgomot de fundal specific rețelelor de telefonie.

Pe lângă dataset-urile publice, literatura recentă indică o tendință clară către utilizarea datelor sintetice generate pentru antrenarea modelelor de fraudă. Setul de date “fraud\_call.file” de pe platforma kaggle demonstrează importanța simulării dialogurilor de tip scam folosind LLM-uri [Yad23]. Pentru simularea apelurilor frauduloase, se pot folosi motoare TTS precum *gTTS* (Google Text-to-Speech), menționat de Durette [Dur24], iar realismul poate fi sporit prin adăugarea de zgomot de fundal din librării precum *Freesound* [Fre].

## 2.5 Analiză critică a literaturii de specialitate

Analiza lucrărilor din domeniu arată clar că abordările vechi, care se bazau pe metadate și reguli simple, nu mai fac față atacurilor moderne. De aceea, cercetarea a trecut spre metode proactive, care lucrează direct cu semnalul audio. Studiile analizate confirmă că reprezentările spectrale, în special mel-spectrogramele, împreună

cu rețelele CNN, oferă cele mai bune rezultate pentru distincția generală dintre vocea umană și cea sintetică.

Cu toate acestea, există lacune semnificative care motivează cercetarea de față. În primul rând, se observă o discrepanță de performanță între detectarea roboților simpli și a spam-ului uman sau a deepfake-urilor avansate. În al doilea rând, problema audio-ului parțial falsificat (*Partially Fake*) rămâne nerezolvată, modelele actuale eșuând în a detecta modificările locale fine.

Prin urmare, contribuțiile propuse în această lucrare vizează optimizarea feature-urilor spectrale prin comparații directe între spectrograma simplă, spectrograma Mel și MFCC. În plus, se vor utiliza modele hibride și ensemble (DL + ML) pentru a aborda spam-ul uman și audio PF, pe baza caracteristicilor paralingvistice și spectrale.

# Capitolul 3

## Fundamente teoretice

### 3.1 Parametrizarea spectrală

În procesul de transformare a semnalului audio în reprezentare vizuală, alegerea numărului de benzi Mel ( $n_{mels}$ ) este critică pentru echilibrul dintre rezoluția caracteristicilor și complexitatea computațională a modelului CNN. În prezenta lucrare, s-a optat pentru valoarea  $n_{mels} = 128$  din trei considerente fundamentale:

Scala Mel este proiectată pentru a simula modul în care urechea umană percepe frecvențele, punând accent pe frecvențelor joase, unde sunt concentrate majoritatea trăsăturilor distinctive ale vorbirii. O valoare de 128 de benzi oferă o granularitate suficientă pentru a captura nuanțele paralingvistice și artefactele fine generate de motoare Text-to-Speech sau elemente esențiale în detecția atacurilor de tip partially fake.

Utilizarea unei puteri a lui 2 ( $2^7 = 128$ ) ajută placa video (GPU) să proceseze datele mult mai rapid și optimizează operațiile de convoluție prin reducerea padding-ului necesar la nivelul straturilor de filtrare. Mai mult, această dimensiune generează o „imagine” spectrală cu un raport de aspect compatibil cu arhitecturile CNN standard, evitând o densitate excesivă de parametri în straturile complet conectate (*fully connected*), ceea ce ar putea conduce la fenomenul de overfitting pe seturi de date de dimensiuni medii.

O rezoluție mai mare de 128 pentru voce umană (eșantionată la 16kHz) introduce redundanță. Benzile Mel ar deveni atât de înguste încât ar captura zgomot de fond sau variații irelevante ale vocii, ceea ce ar face modelul mai puțin capabil să generalizeze pe apeluri reale cu zgomot de canal.

# Capitolul 4

## Dezvoltarea aplicației

### 4.1 Definiția problemei

- ce se va rezolvare prin aplicație?

### 4.2 Analiza și arhitectura aplicației

- aspecte de arhitectură ce trebuie discutate + o diagramă
- cerințe funcționale / nefuncționale
- diagramă de cazuri de utilizare, diagramă de arhitectură,
- diagramă de pachete

### 4.3 Dezvoltarea Aplicației

- Descrierea procesului de dezvoltare al aplicației, configurații, ce se urmărește
- Tehnologii folosite, structură
- și dacă sunt: diagrame de clase, modele folosite în DB

### 4.4 Manual de utilizare

- cum se poate folosi aplicatia

### 4.5 Testare

- ce teste s-au făcut
- ce tip de testare s-a folosit: testare unitară, de integrare, testare manuală etc.

# Capitolul 5

## Experimente

În acest capitol sunt prezentate experimentele realizate pentru evaluarea și compararea modelelor antrenate. Structura urmată este următoarea: mai întâi sunt prezentate rezultatele pe setul intern de testare (Train/Val/Test split), apoi validarea statistică prin  $K$ -Fold Cross-Validation, și în final evaluarea pe un set de date complet extern, necunoscut modelului în timpul antrenamentului.

### 5.1 Performanța pe setul intern de testare

Tabelul 5.1 prezintă performanța fiecărui model pe setul intern de testare (date rezervate din setul principal, dar nevăzute în timpul antrenamentului). Modelele v10–v13 reprezintă un studiu de ablație pornind de la configurația v8 (cea mai bună configurație obținută cu Optuna), în care am dezactivat pe rând câte o componentă pentru a măsura contribuția individuală a fiecărei tehnici.

Tabela 5.1: Comparația modelelor pe setul intern de testare

| Model                     | Accuracy (%) | Precision | Recall | $F_1$ | Params  |
|---------------------------|--------------|-----------|--------|-------|---------|
| OldCNN (v5)               | 97.462       | 0.986     | 0.966  | 0.976 | ~9.3K   |
| CNN (v6)                  | 98.073       | 0.994     | 0.972  | 0.983 | ~455.1K |
| CNN + Optuna (v8)         | 98.874       | 0.998     | 0.980  | 0.989 | ~455.1K |
| v8 No Augment (v10)       | 99.019       | 0.998     | 0.983  | 0.990 | ~455.1K |
| v8 No Class Weights (v11) | 99.086       | 0.997     | 0.986  | 0.991 | ~455.1K |
| v8 No Dropout (v12)       | 99.099       | 0.998     | 0.984  | 0.991 | ~455.1K |
| v8 Fixed LR (v13)         | 99.165       | 0.999     | 0.985  | 0.992 | ~455.1K |
| ResNet18 (v9)             | 98.927       | 0.996     | 0.983  | 0.990 | ~11.2M  |

Se poate observa că trecerea de la OldCNN (v5, ~9.3K parametri) la noua arhitectură CNN (v6, ~455.1K parametri) a adus o creștere a scorului  $F_1$  de la 0.976 la 0.983. Optimizarea hiperparametrilor cu Optuna (v8) a îmbunătățit scorul la 0.989. Modelul ResNet18 (v9), deși are ~11.2M parametri (de 24 de ori mai mulți decât

CNN-ul nostru), nu a reușit să depășească performanța v8, obținând un  $F_1$  de 0.990. Acest rezultat demonstrează că o arhitectură mai mică, proiectată specific pentru spectrograme Mel, poate rivaliza cu un model pre-definit mult mai mare.

Studiul de ablație (v10–v13) arată că eliminarea individuală a fiecărei componente (augmentare, class weights, dropout, scheduler cosinus) nu degradează semnificativ performanța pe setul intern. Însă, așa cum vom vedea în secțiunile următoare, aceste tehnici devin esențiale atunci când modelul este evaluat pe date externe cu distribuții diferite.

## 5.2 Validarea statistică prin $K$ -Fold Cross-Validation

Pentru a evalua capacitatea de generalizare a modelului (v8) pe date nemaivăzute și pentru a minimiza riscul de supra-antrenare *overfit*, s-a utilizat o metodă de validare încrucișată *cross-validation* cu 5 iterații (straturi). Performanța este raportată sub forma unei medii aritmetice a scorurilor  $F_1$  obținute pe fiecare strat, împreună cu deviația standard ( $\sigma$ ), conform următoarelor formule:

$$\mu_{F1} = \frac{1}{k} \sum_{i=1}^k F_{1,i} \quad (5.1)$$

$$\sigma = \sqrt{\frac{\sum_{i=1}^k (F_{1,i} - \mu_{F1})^2}{k}} \quad (5.2)$$

Rezultatul final de  $99.13\% \pm 0.24\%$  indică o stabilitate ridicată a arhitecturii propuse. Deviația standard redusă ( $\sigma = 0.24\%$ ) sugerează o varianță minimă a performanței între diferitele partiții de date, dovedind astfel că rețeaua neuronală convoluțională (CNN) a capturat trăsături acustice fundamentale capabile să identifice cu precizie un apel malițios.

Tabela 5.2: Metrice de performanță de-alungul a 5 straturi de validare încrucișată.

| Strat                    | Pierdere (Validare) | Scor $F_1$ maxim |
|--------------------------|---------------------|------------------|
| Fold 1                   | 0.0477              | 0.9903           |
| Fold 2                   | 0.0285              | 0.9931           |
| Fold 3                   | 0.0377              | 0.9929           |
| Fold 4                   | 0.0287              | 0.9931           |
| Fold 5                   | 0.0747              | 0.9870           |
| <b>Medie</b>             | <b>0.0434</b>       | <b>0.9913</b>    |
| <b>Deviația Standard</b> | <b>0.0171</b>       | <b>0.0024</b>    |



### 5.3 Evaluarea modelului pe date externe

Pentru evaluarea modelului pe date externe am folosit setul de date de test oferit de [AA23] ce conține audio-uri *Partially Fake*, acesta conține  $\sim 7400$  de fișiere audio malițioase. În plus, au fost adunate video-uri de pe YouTube unde apelantul vorbește cu un scammer la telefon,  $\sim 37$  minute, și audio-uri cu discuții normale între 2 persoane care însumează  $\sim 121$  de minute, aceste video-uri (Nu de la VigilisY-tVideos) normale au fost procesate astfel încât fiecare audio a fost împărțit în mai multe audio-uri de câte 1 minute. În fiecare fereastră de câte 6 secunde s-a inserat voce sintetizată folosind un motor de TTS. Modelul v8 nu a reușit să detecteze niciun apel generat de noi ca fiind malițios, mai mult, în majoritatea apelurilor acesta nu a recunoscut nici măcar o singură spectrogramă ca fiind malițioasă 5.1. Pe lângă cele 121 de minute de audio folosind pentru generarea de audio-uri PF, prin YouTube am făcut rost și de 60 de minute de audio ce reprezintă podcast-uri sau interviuri tehnice folosite ca date nemalițioase pentru validarea modelului.




Figura 5.1: Modelul v8 nu a recunoscut spectrogramele *Partially Fake*

#### 5.3.1 Ajustarea fină cu date *Partially Fake*

Toate audio-urile în care am inserat voce sintetizată au fost adăugate mai apoi în setul nostru de date malițios deoarece aproximativ fiecare spectrogramă este de tipul *PartiallyFake*, după care am antrenat modelul pe toate datele rezultând modelul v14 5.3. Pentru evaluarea modelului nou și a-l compara cu v8 a trebuit să aducem noi date de pe YouTube (131 minute) ce reprezintă podcast-uri sau interviuri normale între 2 persoane și să aplicăm din nou logica de inserție a vocii sintetizate la intervale de timp aleatorii la fiecare 6 secunde.

Modelul v14 a reușit să captureze 129 din 131 de audio-uri PF generate de noi ca fiind malițioase, iar modelul v8 nu a clasificat niciun apel ca fiind malițios, clasi-

Tabela 5.3: Evaluarea performanței modelului CNN v14

| Model     | Accuracy (%) | Precision | Recall | $F_1$ | Params  |
|-----------|--------------|-----------|--------|-------|---------|
| CNN (v14) | 96.217       | 0.938     | 0.986  | 0.962 | ~455.1K |

ficand greșit fiecare apel. După ce am evaluat ambele modele pe datele externe, 60 minute audio normal, 7440 audio PF din setul de date [AA23], 131 minute audio PF generat de noi și 37 de minute audio de tip *scam call* am generat matricea de confuzie pentru ambele modele. Se poate observa ca modelul anterior clasifică mai bine apelurile normale 5.2, modelul v14 fiind mai agresiv 5.3, dar clasifică exceptional de bine apelurile malițioase generate de noi, care este o problemă pentru v8 deoarece din 139 de apeluri malițioase clasificate ca normale, 131 sunt PF create de noi 5.4.

Tabela 5.4: Comparatie între modelele v8 și v14 pe date externe

| Model            | Normal Recall (%) | Malicious Recall (%) | $F_1$ (macro) |
|------------------|-------------------|----------------------|---------------|
| v8 (Original)    | 78.0              | 98.2                 | 0.68          |
| v14 (Fine-Tuned) | 47.0              | 99.9                 | 0.80          |





Figura 5.2: Modelul v8


Figura 5.3: Modelul v8 *fine tuned* (v14)

### 5.3.2 Reechilibrarea setului de date

Observând ca noul model nu se descurcă bine clasificând apelurile normale am continuat să folosim YouTube pentru a aduna date normale folosind podcast-uri care se aseamăna puternic cu un apel telefonic. Am adunat  $\sim 210$  minute de audio normal și  $\sim 70$  minute de audio malițios ce reprezintă apeluri reale între victima și scammer, deoarece setul de date malițios pe care îl folosim este ușor imbalansat conținând mai multe audio-uri din setul de date RFP [AA23] decât apeluri reale înregistrate.

Tabela 5.5: Evaluarea performanței modelului CNN v15

| Model     | Accuracy (%) | Precision | Recall | $F_1$ | Params        |
|-----------|--------------|-----------|--------|-------|---------------|
| CNN (v15) | 98.314       | 0.983     | 0.987  | 0.985 | $\sim 455.1K$ |

Figura 5.4: Modelul v14 *fine tuned* (v15)

Modelul v15 a îmbunătățit semnificativ clasificarea apelurilor normale comparativ cu v14 (Normal Recall: 76% față de 47%), însă a pierdut din capacitatea de a detecta audio-urile *Partially Fake* generate de noi (72 din 131, față de 129 din 131 pentru v14). Din cele 63 de apeluri clasificate greșit ca normale, 59 sunt audio-uri PF generate prin inserția de voce sintetizată.

Acest comportament se explică prin natura datelor adăugate la antrenament. Modelul v14 a fost ajustat fin (*fine-tuned*) exclusiv pe date PF adăugate în clasa malițioasă, ceea ce l-a determinat să devină foarte agresiv în clasificare — orice semnal care conținea voce sintetizată era marcat ca malițios, dar în același timp clasifica greșit multe apeluri normale. Pentru v15, am adăugat ~210 minute de conversații normale (podcast-uri, interviuri) și ~70 de minute de apeluri reale cu scammeri. Aceste date suplimentare au reechilibrat granița de decizie a modelului, învățându-l că o voce clară nu înseamnă automat un apel fraudulos. Deși audio-urile PF conțin inserții de voce sintetizată în fiecare fereastră de 6 secunde (ocupând aproximativ 25–50% din fiecare fereastră), modelul reechilibrat a învățat din datele normale suplimentare să nu mai clasifice agresiv orice voce clară ca fiind malițioasă, rezultând într-un compromis între precizia pe clasa normală și capacitatea de detectare a audio-urilor PF.

## 5.4 Simularea canalului telefonic

În urma testării aplicației Streamlit, s-a observat fenomenul de *shortcut learning* (învățare prin scurtătura). Modelul tindea să clasifice semnalele audio înregistrate prin microfoane uzuale precum cel de la laptop sau telefon ca fiind malițioase, indiferent de conținutul semantic. Aceasta indică faptul că rețeaua a învățat să asocieze defectele audio și zgomotul de fundal cu clasa "malicious", deoarece setul de date de antrenament pentru această clasă provenea predominant din surse cu o calitate inferioară (înregistrări YouTube, apeluri comprimate).

Pentru a rezolva aceasta problemă am implementat o funcție de augmentare care simulează un canal telefonic, ea este aplicată cu o probabilitate de 50% audio-ului chiar înainte de a fi generată spectrograma. Aceasta aplică un lanț de degradări controlate care simulează limitările fizice și digitale ale unui canal telefonic tradițional. Etapele procesului de degradare sunt următoarele:

1. **Filtrarea de bandă (*Bandpass Filtering*).** Codecurile telefonice tradiționale (POTS<sup>1</sup>) și cele celulare transmit doar frecvențele din intervalul 300–3 400 Hz. Am simulat această limitare aplicând un filtru Butterworth de ordinul 4, cu pragurile de tăiere randomizate ușor ( $\pm 50$  Hz) pentru a introduce variabilitate. Această filtrare elimină frecvențele joase (sub 300 Hz, unde se acumulează zgomotul electric) și frecvențele înalte (peste 3 400 Hz, responsabile de claritatea și strălucirea vocii), forțând modelul să clasifice vorbirea exclusiv pe baza benzii de frecvență specifice telefoniei.
2. **Sub-eșantionarea și re-eșantionarea (*Resampling*).** Semnalul audio este redus de la frecvența de eșantionare originală de 16 kHz la 8 kHz (rata standard a codecului AMR-NB) și apoi re-eșantionat înapoi la 16 kHz. Conform teoremei Nyquist, sub-eșantionarea la 8 kHz elimină permanent toate componentele de frecvență peste 4 kHz, iar procesul de reconstrucție introduce artefacte (*aliasing*) similare celor produse de compresia vocală celulară.
3. **Adăugarea zgomotului de fundal.** Se generează zgomot Gaussian alb și se suprapune peste semnal la un raport semnal-zgomot (SNR<sup>2</sup>) ales aleatoriu din intervalul 10–25 dB. Un SNR de 10 dB simulează un mediu zgomotos (stradă, transport public), iar unul de 25 dB corespunde unui spațiu interior liniștit cu zgomot electronic rezidual. Prin antrenarea pe ambele extreme, modelul învață să extragă trăsăturile relevante ale vorbirii indiferent de nivelul de zgomot ambiant.

<sup>1</sup>Plain Old Telephone Service

<sup>2</sup>Signal-to-Noise Ratio

4. **Distorsiunea de tip *clipping*.** Amplitudinea semnalului este trunchiată la un prag aleatoriu cuprins între 60% și 90% din valoarea maximă. Acest efect simulează saturarea microfonului sau a amplificatorului, fenomen frecvent atunci când vorbitorul se află prea aproape de microfon sau vorbește la un volum ridicat. Spectrograma rezultată prezintă armonici suplimentare pe care modelul trebuie să le ignore.
5. **Variația de volum și normalizare.** Volumul semnalului este scalat cu un factor aleatoriu între  $0.5\times$  și  $1.5\times$ , după care amplitudinea maximă este normalizată la 1.0 (0 dBFS<sup>3</sup>). Această etapă previne modelul din a utiliza intensitatea sonoră absolută ca trăsătură discriminativă, forțându-l să se bazeze exclusiv pe distribuția relativă a energiei în spectrogramă.

Augmentarea a fost aplicată în mod egal ambelor clase (normală și malițioasă), asigurând că modelul nu asociază degradarea canalului telefonic cu nicio etichetă specifică.

### 5.4.1 Rezultate

Modelul v16 folosește aceeași arhitectură CNN ca și v15 (~455.1K parametri), antrenat pe același set de date, dar cu funcția de simulare a canalului telefonic activată în etapa de generare a spectrogramelor.

Tabela 5.6: Evaluarea performanței modelului v16 (CNN + simulare telefonie)

| Model     | Accuracy (%) | Precision | Recall | $F_1$ | Params  |
|-----------|--------------|-----------|--------|-------|---------|
| CNN (v16) | 93.06        | 0.915     | 0.971  | 0.942 | ~455.1K |

Modelul v17 trece la o nouă arhitectura numita Enhanced CNN conceputa din pricina faptului ca setul nostru de date a trecut de 75K de spectrograme comparativ cu 40K cate am avut cand am adoptat ultima versiune de CNN. Am trecut de la blocuri de o singură convoluție la blocuri de convoluții duble (ex: două straturi de 64 canale, urmate de două de 128). Această structură permite rețelei să învețe transformări mai complexe și non-liniare înainte de reducerea dimensiunii prin *Pooling*. Numărul maxim de filtre a fost mărit de la 256 la 512 în ultimul strat convoluțional, oferind modelului o capacitate mult mai mare de a distinge între zgomotul de fundal și artefactele specifice apelurilor malițioase. Am implementat o schemă de Dropout incremental (0.1, 0.15, 0.2) pe parcursul straturilor. Această abordare previne overfitting-ul neuronilor încă din primele etape ale extracției de trăsături.

<sup>3</sup>Decibels relative to Full Scale

Tabela 5.7: Evaluarea performantei modelului v17 (Enhanced CNN + simulare telefonie)

| Model              | Accuracy (%) | Precision | Recall | $F_1$ | Params |
|--------------------|--------------|-----------|--------|-------|--------|
| Enhanced CNN (v17) | 94.229       | 0.923     | 0.982  | 0.952 | ~2.45M |

În continuare, pentru optimizarea parametrilor rețelei, am ales algoritmul AdamW [LH17], o variantă corectată a algoritmului Adam [KB14]. Diferența fundamentală constă în modul de aplicare a regularizării L2 (weight decay). În Adam clasic, penalizarea ponderilor este cuplată cu rata de învățare, ceea ce înseamnă că atunci când rata de învățare scade (de exemplu, prin scheduler-ul CosineAnnealing), efectul regularizării scade proporțional, un comportament nedorit. AdamW decuplează weight decay de rata de învățare, asigurând o regularizare constantă pe tot parcursul antrenamentului, indiferent de variațiile ratei de învățare impuse de scheduler. Această proprietate este esențială în configurația noastră, unde utilizăm CosineAnnealingWarmRestarts ca scheduler, un algoritm care variază agresiv rata de învățare între o valoare maximă și un minim de  $1e - 6$ . Combinația AdamW + CosineAnnealingWarmRestarts este considerată o practică standard în literatura recentă de deep learning [LH17].

Folosind configurația finală a Rețelei Neuronale Convolutionale și împreună cu setul de date folosit pentru v17 am rulat un proces de gasire a hiperparametrilor optimi folosind Optuna și Median Pruning (Oprirea unei rulări devreme dacă după 5 epoci cea mai bună funcție de loss este mai slabă decât media rezultatelor anterioare) pentru a găsi hiperparametrii optimi pe parcursul a 4 ore (37 trial-uri rulate). Căutarea a relevat că un Dropout mai mare (54%) și un Batch Size de 32 sunt optime, ceea ce ne spune că modelul tindea să dea overfit, un label smoothing aproape de 0 (0.0002) ce ne arată că setul de date e curat și zgomotul de etichetare este minim și un weight decay de 0.000414.

Tabela 5.8: Evaluarea performantei modelului v18 (v17 + Optuna)

| Model     | Accuracy (%) | Precision | Recall | $F_1$ | Params  |
|-----------|--------------|-----------|--------|-------|---------|
| CNN (v16) | 93.06        | 0.915     | 0.971  | 0.942 | ~455.1K |

## 5.5 Comparația finală și discuție

Tabelul 5.9 sintetizează performanța celor trei modele pe setul de evaluare externă.

Rezultatele evidențiază un compromis între capacitatea de a clasifica corect ape-

Tabela 5.9: Comparație între modelele v8, v14 și v15 pe date externe

| Model              | Normal Recall (%) | Malicious Recall (%) | PF detectate | $F_1$ (macro) |
|--------------------|-------------------|----------------------|--------------|---------------|
| v8 (Original)      | 78.0              | 98.2                 | 0 / 131      | 0.68          |
| v14 (Fine-Tuned)   | 47.0              | 99.9                 | 129 / 131    | 0.80          |
| v15 (Reechilibrat) | 76.3              | 99.2                 | 72 / 131     | 0.77          |

lurile normale și cea de a detecta audio-uri *Partially Fake*. Modelul v8 rămâne cel mai echilibrat pentru clasificarea apelurilor în întregime normale sau malițioase, iar v14 este indicat atunci când detectarea inserțiilor de voce sintetizată este prioritară. Modelul v15 oferă un echilibru intermediar, demonstrând că îmbogățirea setului de date cu exemple diverse îmbunătățește generalizarea, dar evidențiază totodată limitarea abordării bazate pe vot majoritar pentru audio-uri predominant normale.

Este de menționat că evaluarea pe date externe a pus în evidență problema schimbării de domeniu (*domain shift*): un model antrenat pe un anumit tip de audio (de exemplu, apeluri din corpusul RFP) nu generalizează automat pe audio-uri din surse diferite (de exemplu, podcast-uri descărcate de pe YouTube). Diferențele de calitate audio, zgomot de fundal, accent și stil de vorbire contribuie toate la această problemă. Aceste observații motivează direcțiile de cercetare viitoare prezentate în Capitolul 6, în special adoptarea unor tehnici de analiză la nivel de fereastră individuală (*per-window analysis*) în locul votului majoritar, precum și utilizarea mai multor motoare TTS pentru a crește diversitatea datelor sintetice.



# Capitolul 6

## Concluzii

Concluzii ...

# Anexa A

## YouTube Dataset Sources

Tabela A.1: Video-uri de pe YouTube folosite in seturile noastre de date malitioase

| Titlu Video                                                       | Canal YouTube              | Link                 |
|-------------------------------------------------------------------|----------------------------|----------------------|
| <b>Partea 1: Set Principal (Antrenament, Validare si Testare)</b> |                            |                      |
| <i>1.1. Audio-uri cu Character Malitios</i>                       |                            |                      |
| How do Microsoft pop up scammers work (Longest bait-part 1)       | How To Delete              | <a href="#">link</a> |
| Super Scammer Vs. Scammer Spree! - The Hoax Hotel                 | The Hoax Hotel             | <a href="#">link</a> |
| The Scummiest Scam I've Called - The Hoax Hotel                   | The Hoax Hotel             | <a href="#">link</a> |
| The Angriest Scammer I've Ever Called - The Hoax Hotel            | The Hoax Hotel             | <a href="#">link</a> |
| IRS Scammer called the wrong one                                  | Mr. White                  | <a href="#">link</a> |
| Phone call with HMRC fraudster in UK 2021                         | ScammersWorldwide          | <a href="#">link</a> |
| Raging Scammers Transfer \$46,000 to me                           | Scammer Payback            | <a href="#">link</a> |
| The Cop and The Scammer TWO - Microsoft Technical Support Scam    | Victoria Police Department | <a href="#">link</a> |
| Phone Scammer Gets Scammed by Police Captain                      | NowThis Impact             | <a href="#">link</a> |
| Installing 100 Viruses - Calling Tech Support Scammers            | Kitboga                    | <a href="#">link</a> |
| Entire Scam Call Center Goes Mad While I Redeem Gift Cards        | Kitboga                    | <a href="#">link</a> |
| Continuare pe pagina următoare                                    |                            |                      |

Tabela A.1 – continuare de la pagina anterioară

| Titlu Video                                                   | Canal YouTube    | Link |
|---------------------------------------------------------------|------------------|------|
| Spending All My Money While Scammers Watch                    | Kitboga          | link |
| Scammer Lost His Mind After Failed SYS-KEY                    | Kitboga          | link |
| Man Receives Call From Scammer and Proceeds to Waste his Time | Storyful Viral   | link |
| <b>1.2. Audio-uri Normale</b>                                 |                  |      |
| Data Science Job Interview – Full Mock Interview              | freeCodeCamp.org | link |
| How to solve a Google coding interview question               | Life at Google   | link |
| Elon Musk (Full Interview) — Real Time with Bill Maher (HBO)  | Real Time        | link |
| Elon Musk's Work Ethics Will Give You Goosebumps              | Rise Above       | link |
| The secret to Elon Musk's productivity                        | Lex Clips        | link |
| <b>Partea 2: Setul de Evaluare Externă</b>                    |                  |      |
| <b>2.1. Audio-uri Normale</b>                                 |                  |      |
| Jane Street Software Engineering Mock Interview               | Jane Street      | link |
| Jane Street Trading Mock Interview                            | Jane Street      | link |
| Behavioral Mock Interview with Staff ML Engineer              | Andrey Tech      | link |
| Jane Street Quant Trading Interview!                          | Quant Blueprint  | link |
| <b>2.2. Audio-uri cu Caracter Malitios</b>                    |                  |      |
| SCAMMING the SCAMMER in 5 voices!                             | IRLrosie         | link |
| Messing with phone scammers                                   | Officer Daniels  | link |
| HOW TO HANDLE A PHONE SCAM                                    | PettyPranks      | link |
| FREAKING OUT SCAMMERS - w/Voice Acting !                      | IRLrosie         | link |
| DEALING WITH AN IMPATIENT PHONE SCAMMER                       | PettyPranks      | link |
| Card Services Scam Call EXPOSED                               | The Basic Pilot  | link |

Tabela A.2: Video-uri de pe YouTube folosite in seturile noastre de date non-malitioase

| Titlu Video                                                                                         | Canal YouTube                       | Link          |
|-----------------------------------------------------------------------------------------------------|-------------------------------------|---------------|
| <b>Partea 1: Set Principal (Antrenament, Validare si Testare)</b>                                   |                                     |               |
| Claude Shannon at MIT: The best master's thesis in history                                          | Lex Clips                           | link to video |
| Communicate with Confidence:The Blueprint for Mastering Every Conversation                          | Mel Robbins                         | link to video |
| Elon Musk: Advice for Young People                                                                  | Lex Clips                           | link to video |
| Job Interview Good Example copy                                                                     | Katherine Johnson                   | link to video |
| The Morality of CIA Assassins w/ Annie Jacobsen                                                     | URE Clips                           | link to video |
| Learn English quickly with podcast — English learning Conversation                                  | English Podcast Zone                | link to video |
| President Barack Obama Between Two Ferns with Zach Galifiana                                        | Funny or Die                        | link to video |
| The AI Revolution: Myths, risks, and opportunities                                                  | Harvard Business School             | link to video |
| The Layers of Intelligence Agencies Involved in Assassination                                       | JRE Clips                           | link to video |
| US debt is growing by 1 trillion every 100 days.                                                    | Lex Clips                           | link to video |
| When did you know she was the one for you? (Good Will Hunting)                                      | Jonathan Jee                        | link to video |
| the mother-daughter dynamic, a talk with my mom                                                     | anything goes with emma chamberlain | link to video |
| Your Mom's House Podcast w/ Andrew Tate - Ep.636                                                    | YMH Studios                         | link to video |
| <b>Partea 2: Setul de Evaluare Externă (Date complet noi)</b>                                       |                                     |               |
| How to stay calm when you know you'll be stressed — Daniel Levitin — TED                            | TED                                 | link to video |
| Is breakfast really the most important meal of the day? - The Food Chain podcast, BBC World Service | BBC World Service                   | link to video |
| The Most Eye Opening 10 Minutes Of Your Life — David Goggins                                        | Motivation Madness                  | link to video |

# Bibliografie

- [AA23] George Theodorakopoulos Abdulazeez AlAli. An rfp dataset for real, fake, and partially fake audio detection, 2023. Dataset size: 40.4 GB, containing Real, Fake, and Partially Fake (PF) audio samples.
- [AT] Abdulazeez AlAli and George Theodorakopoulos. An rfp dataset for real, fake, and partially fake audio detection. <https://arxiv.org/pdf/2404.17721>.
- [BD21] Elizalde Benjamin and Emmanouilidou Dimitra. Detection of robocall and spam calls using acoustic features of incoming voicemails. In *Proc. Mtgs. Acoust*, page 060004. ASA, POMA, December 2021.
- [Dir24] Asociația Română a Băncilor (ARB) Directoratul Național de Securitate Cibernetică (DNSC), Poliția Română. Avertizare privind riscul de fraudă prin apeluri telefonice false (spoofed). <https://www.dnsc.ro/vezi/document/comunicat-de-presa-directoratul-national-de-securitate-cibernet> May 2024. Comunicare oficială de presă, proiectul național de conștientizare SigurantaOnline.
- [Dur24] Pierre Nicolas Durette. gtts: A python library and cli tool to interface with google’s text-to-speech api. <https://github.com/pndurette/gTTS>, 2024.
- [ED21] Benjamin M Elizalde and Emmanouilidou Dimitra. Audio-based spam call detection. *The Journal of the Acoustical Society of America*, 150(4):A357–A357, December 2021. Acoustical Society of America.
- [Fre] Freesound - the free sound library. <https://freesound.org>. Online audio repository for background sounds and augmentation.
- [Inf24] InfoCons. Ce trebuie să știm despre apelurile false și spoofing. <https://infocons.ro/ce-trebuie-sa-stim-despre-apelurile-false-si-spoofing/>,

2024. Articol informativ despre riscurile apelurilor spoofed și recomandări pentru utilizatori.
- [KASF21] Abdullah Johari Khan Adnan Shahid, Ahmad Zeeshan and Ahmad Farhan. A spectrogram image-based network anomaly detection system using deep convolutional neural network. *IEEE Access*, 9:87079–87093, 2021.
- [KB14] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *CoRR*, abs/1412.6980, 2014.
- [KLLK25] Seong-Yoon Kim, Hyun-Min Lee, Chae-Young Lim, and Hyun-Woo Kim. Detection of abnormal symptoms using acoustic-spectrogram-based deep learning. *Applied Sciences*, 15(9), 2025.
- [(LD97] Linguistic Data Consortium (LDC). Callhome american english speech. <https://www.kaggle.com/datasets/kiennngx/callhome-dataset>, 1997. Set de date ce conține conversații telefonice reale, utilizat pentru antrenarea modelelor de recunoaștere și clasificare a vorbirii. Versiune accesată prin platforma Kaggle.
- [LH17] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2017.
- [MLZ24] YASAMAN AHMADIADLI MENGLU LI and XIAO-PING ZHANG. Audio anti-spoofing detection: A survey. *Pre-print: arXiv*, 2024. Comprehensive review covering features (CQCC, RawNet2, MFCC), classification architectures, and datasets, highlighting CQCC effectiveness for low-frequency artifact detection.
- [Pot24] Divya Potnuru. Spam call detection using machine learning. *International Journal of Research Publications and Reviews*, 2024. Review of traditional ML methods (Naive Bayes, Random Forests, Adaptive Boosting) and the use of Call Detail Records (CDR) for spam detection.
- [Sat23] Sathvik Prasad and Bradley Reaves. Robocall Audio from the FTC’s Project Point of No Entry. Technical Report TR-2023-1, North Carolina State University, Nov 2023.
- [TDE16] Massimiliano Todisco, Héctor Delgado, and Nicholas Evans. A new feature for automatic speaker verification anti-spoofing: Constant q cepstral coefficients. In *The Speaker and Language Recognition Workshop (Odyssey 2016)*, pages 283–290, 2016.

- [TO19] {Nam H.} Trinh and Darragh O'Brien. Pathological speech classification using a convolutional neural network. January 2019. IMVIP 2019: Irish Machine Vision & Image Processing ; Conference date: 28-08-2019 Through 30-08-2019.
- [Tru21] Truecaller. Truecaller insights: Us spam & scam report 2021. <https://www.truecaller.com/blog/insights/us-spam-scam-report-21>, 2021. Raport care estimează pierderi financiare de aproape 30 miliarde USD.
- [Yad23] Narayan Yadav. Fraud call detection dataset. <https://www.kaggle.com/datasets/narayanyadav/fraud-call-india-dataset>, 2023. Set de date ce conține text fraudulos sau normal. Conține doar propozitiile apelantului.